

社交導航避障：從幾何限制到全域注意力的演進與突破

技術專題研究報告

作者： 邱建彰、粘肇 生成工具支援： NotebookLM

摘要 (Abstract)

隨著智慧製造、智慧零售以及照護醫療等場域的迅速擴展，服務型機器人 (Service Robots) 在人類生活空間中的普及率正以顯著的速度攀升。在這些高度動態且充滿不確定性的人類共享環境中，如何讓機器人具備流暢、安全且符合人類社交規範的導航能力，已成為當前機器人學 (Robotics) 與人工智慧 (AI) 領域最具挑戰性的核心課題之一。傳統的導航系統主要依賴點到點的靜態全域路徑規劃 (Global Planning) 與基於幾何反應式的局部避障 (Local Planning)。然而，這類方法本質上將人類粗暴地視為普通的「動態障礙物」或「盲目死物」，在實際擁擠場域中往往會引發「晚期反應」、「破壞社交連結」以及「機器人凍結 (Frozen Robot Problem)」等三大致命盲區。

為了破解此一學術與工程瓶頸，本報告深入探討一種基於全域注意力機制 (Global Attention Mechanism) 的深度強化學習導航架構——**OM-SARL (Occupancy Grid Map - Relation Network based Social-Aware Reinforcement Learning)**。該架構將導航問題建模為馬可夫決策過程 (MDP)，並精妙地結合了**互動模組 (Interaction Module)**與**動態注意力權重分配模組 (Pooling Module)**。透過在特徵工程上引入由機器人與行人交互催生的局部地圖 (Local Map) 編碼，該網路能在大腦決策前預先顯式萃取幾何關係，並利用 Softmax 歸一化層計算出各行人的動態重要性權重 α_i ，最終將其凝聚成一個無損的 50 維全域社交特徵向量 c 。

本研究於配備 Intel i7-10700 CPU 與 NVIDIA RTX 3070TI GPU 的硬體平台上，採用 PyTorch 深度學習框架進行雙階段訓練（包含 3000 次模仿學習與 10000 次強化學習）。實驗數據指出，在 500 局標準極端擁擠測試中，OM-SARL 達成了驚人的 **100% 導航成功率**與 **0% 碰撞率**，其平均導航時間僅需 10.57s，且成功將社交危險平均距離維持在 0.16m，在各項核心幾何指標與社交禮儀表現上，均以壓倒性優勢全面超越傳統的 ORCA 幾何演算法、CADRL 以及 LSTM-RL 學習模型。儘管全域注意力機制帶來了矩陣博弈運算量的大幅上升，使得整體訓練時間成本增加了 85%（達 26.4 小時），但其所換取的完美安全性與最優即時決策效率，為下一代具備意圖感知 (Intention-Aware) 能

力的社交導航機器人奠定了堅實的理論與技術藍圖。

第一章：緒論：移動機器人導航的演進與傳統盲區

1.1 服務型機器人導航的三大演進階段

移動機器人導航技術的發展軌跡，本質上是一部從「機械式空間幾何計算」走向「人類意圖與社交規範感知」的進化史。通盤審視現代服務型機器人的底層運動控制與路徑規劃，其架構演進主要可劃分為三個核心里程碑：

1. **全域路徑規劃 (Global Planning)** 此階段屬於傳統導航技術的基石，主要解決「點到點 (Point-to-Point) 的靜態路徑規劃」問題。在此模式下，環境地圖通常在機器人出發前即透過 SLAM (同時定位與地圖構建) 技術繪製完成，演算法 (如傳統的 A^* 、Dijkstra 或 RRT 演算法) 在大局觀下尋找一條從起點 A 到終點 B 的無碰最短路徑。此技術的局限性在於其假設世界是「一成不變的死物」，一旦地圖中出現未標註的動態障礙物，全域規劃便會立即失效。
2. **局部反應式避障 (Local Planning)** 為了應對真實世界的動態環境，局部反應式避障應運而生。此階段強調「幾何反應式的局部避障」，機器人透過車載感測器 (如光達 LiDAR、深度相機) 即時掃描周圍幾公尺內的障礙物，並利用如動態視窗法 (DWA) 或時間彈性帶 (TEB) 等幾何控制演算法，動態微調前進速度與轉向角度。然而，此時的導航思維仍將移動的人類等同於會移動的椅子或紙箱，完全缺乏對人類運動行為的社會學解讀。
3. **意圖感知社交導航 (Social Navigation)** 這是現代服務型機器人必須跨越的最高技術階梯。社交導航的核心邏輯在於「意圖感知 (Intention-Aware)」，意即機器人不能僅僅追求在物理幾何上不撞到人，更必須將人類視為具有獨立社交意圖、遵循特殊社會禮儀與心理空間舒適圈 (Psychological Comfort Zones) 的特殊個體。機器人需要提早解讀並預判人類的行走動向，並據此規劃出符合人類預期的、優雅且具備社交規範禮儀的行走軌跡。

[全域路徑規劃: 點到點靜態規劃] ---> [局部反應式避障: 幾何即時避障] ---> [社交導航: 意圖感知博弈]

1.2 傳統機器人導航的三大致命盲區

當傳統的靜態與反應式導航演算法被直接丟進高度擁擠、人機共存的公共場域（如機場、醫院、商場）時，由於其缺乏對人類社交心理與運動不確定性的建模，不可避免地會觸發以下三大「導航盲區」：

- **盲區一：晚期反應 (Late Reaction)**

- **具體現象：**機器人在行進過程中，其大腦大機率會維持原始設定的偏好速度筆直向前衝，直到與行人的物理距離縮短到即將發生「數學幾何碰撞」的臨界點時，感測器警報大作，演算法才驚惶地觸發緊急煞車，並導致極其突兀、尖銳且令人驚嚇的急轉彎。
- **社會學後果：**這種突如其來的機械式急煞與避讓，會給周圍的行人帶來巨大的心理壓迫感與不安全感，嚴重破壞人機共存的信任基石。此現象在經典文獻如 *Chen et al. 2017* 中已被廣泛診斷。

- **盲區二：破壞社交連結 (Conversation Disruption)**

- **具體現象：**在人類社會中，兩位或多位正在站立交談的人，彼此之間會形成一個無形但受心理學保護的「社交舒適空間 (Social Space)」。
- **社會學後果：**這種粗暴穿梭、無視人類社交邊界的行為，會直接強行切斷人類的對話流，屬於嚴重的社交失禮行為。相關瓶頸在 *Alami et al., 2006* 等早期社交導航文獻中即被明確提出。

- **盲區三：機器人凍結 (Frozen Robot Problem)**

- **具體現象：**當環境中的行人數目激增，整個場域變得高度密集與擁擠時，行人的不規則移動會導致空間中可容納機器人安全通過的幾何平面的交集趨近於零。傳統演算法（如幾何半平面剪裁）此時會因為完全無法計算出任何一個絕對安全的速度解，而陷入數學死鎖，最終將機器人的輸出速度直接歸零，使其就地死鎖、動彈不得。
- **社會學後果：**陷入凍結的機器人不但失去了導航能力，它自身反

而淪為了這條擁擠走廊上最大、最頑固的「靜態障礙物」，加劇了人群流動的混亂程度。此經典難題最早由 *Trautman & Krause 2010* 進行了奠基性的數學定量與探討。

第二章：文獻綜述與傳統避障演算法的瓶頸分析

為了解決動態多智能體避障問題，過去數十年來學界發展出了兩大主流派系：**傳統幾何控制派與數據驅動學習派**。本章將依據兩大派系的經典演算法，深度剖析其數學假設以及在面對密集群體時展現的底層瓶頸。

2.1 傳統幾何方法的極限與互惠迷思

2.1.1 速度障礙法 (Velocity Obstacle, VO)

速度障礙法 (VO) 是動態避障領域的元老級幾何方法。其核心思想是在速度空間 (Velocity Space) 中，將障礙物當前的絕對位置與速度映射為一個以機器人為頂點的錐形區域 (Collision Cone)。只要機器人選擇的下一個速度向量落在這個錐形區域之外，就能保證在未來某個時間段內不會與該障礙物發生碰撞。

- **致命缺陷：資訊不對稱與「互惠抖動 (Oscillation)」** VO 演算法在設計上存在一個極其天真的假設——「假設對方是盲目的死物或不會改變策略的單向移動體」。當兩個同樣運行 VO 演算法的機器人迎面相遇時，由於缺乏溝通與雙向預判，雙方都會將對方當成死物，並同時往自己的右邊進行避讓。然而，在下一個控制週期，雙方偵測到對方的速度改變了，又會同時做出反向修正。這種資訊不對稱的動態博弈，會導致兩台機器人在現實中表現為「在原地左右瘋狂、高頻地抖動」，最終在彼此的強烈震盪中迎頭相撞。

2.1.2 最優互惠碰撞避免演算法 (Optimal Reciprocal Collision Avoidance, ORCA)

為了解決 VO 的左右抖動問題，*van den Berg et al.* 於 2011 年提出了著名的 **ORCA** 演算法，這也是目前工業界（如無人搬運車 AGV、無人機群）應用最廣泛的幾何避障架構。ORCA 引入了完美的「互惠動作 (Reciprocal Action)」假設：當機器人與行人（或另一個智能體）面臨碰撞危機時，ORCA 假設雙方都是絕對理性的，且各承擔一半（完美的 50\%/50\% 分配）的避障責任。在數學上，這透過將速度空間切割成多個凸線性約束（線性規劃線性半平

面)，從而為機器人快速求解出一個最優的避障速度。

- **致命缺陷：非合作環境下的互惠迷思與死鎖** ORCA 的精妙之處，恰恰成為了它在真實人類環境中的最大軟肋。真實世界中的人類絕對不是遵循 **50/50 數學互惠原則的理性機器**。當一個人邊走邊滑手機，或者一整群人正在並排聊天時，他們對機器人而言屬於完全的「非合作對象（Non-cooperative Agents）」。此時，機器人單方面死守 ORCA 的 50% 責任承擔假設，會發現自己讓出了 50% 的空間，但人類卻一步也沒有讓。這會直接導致計算凸空間的半平面邊界不斷內縮，最終退化為無解，引發嚴重的「短視近利」與「機器人凍結」問題。

ORCA 互惠架構假設：

機器人避讓 50% <---> 行人避讓 50% (完美理性平衡)

真實人類環境現實：

機器人格守 50% <---> 行人低頭滑手機 (0% 避讓) ---> 機器人空間被壓縮 -
--> 凍結死鎖

2.2 早期深度強化學習模型的演進與瓶頸

隨著深度學習的爆發，科學家開始嘗試利用深度強化學習（DRL）讓機器人透過與環境的大量試錯，自主學習出避障策略，擺脫傳統幾何方法對環境幾何結構的生硬假設。其中最具代表性的是 CADRL 與 LSTM-RL。

2.2.1 CADRL (Collision Avoidance with Deep Reinforcement Learning)

Chen et al. 於 2017 年提出的 **CADRL** 是將 DRL 引入社交避障的先驅工作。它首次證明了透過強化學習的 Reward Function 引導，AI 大腦可以在不需要顯式編碼幾何公式的情況下，學會自發性地從右側通行，展現出類似人類的社交規範避障特徵。

- **技術瓶頸：固定輸入向量與「資訊遺失 (Information Loss)」** CADRL 在多智能體擴充性上遇到了本質上的結構限制。由於傳統多層感知機（MLP）的輸入層維度是完全固定的，CADRL 只能將環境中的行人數目硬性固定（例如只能同時評估 2 到 3 個人），並將他們的狀態按順序拼接成一個長向量。當廣場上的行人數量突然增加到 5 人、10 人或動態

增減時，固定維度的網路便無法直接處理。若採用強行裁切或只挑選最近的 2 個人輸入，則會導致外圍行人的高維動態資訊「徹底遺失 (Information Loss)」，使機器人極易在擁擠人群中顧此失彼，引發嚴重的撞擊。

2.2.2 LSTM-RL (Long Short-Term Memory Reinforcement Learning)

為了克服 CADRL 無法處理動態不定人數 State 的缺點，Everett et al. 2018 引入了循環神經網路中的 LSTM-RL 架構。LSTM 的特性在於其具備時間序列的記憶閘門，可以像吞吐流水帳一樣，以一種類似迴圈的機制 (Loop) 將周圍 1 個到 N 個行人的特徵一個接一個地「依序」餵進 LSTM 單元中，最終輸出一個固定維度的環境特徵向量，從而成功克服了動態人數輸入的時間序列問題。

- **技術瓶頸：無法有效處理「無序性 (Unordered)」的特徵扭曲** LSTM 本質上是為了解決具備嚴格前後順序的「時間序列問題」(如文字、語音)而設計的。然而，在公共廣場上的多個行人 $(H_1, H_2, \dots, H_N)$ ，在空間的分佈上是完全「無序且對稱 (Unordered and Symmetric)」的。這意味著，如果把周圍行人的輸入順序從 $[H_1, H_2, H_3]$ 調換為 $[H_3, H_1, H_2]$ ，對機器人當前的物理危險局勢而言應該是完全等價的。但是，LSTM 會因為輸入順序的先後不同，導致其內部的 Hidden State 產生完全不同的數值扭曲，進而做出截然不同的錯誤決策。這導致 LSTM-RL 在密集、混亂的人群中收斂極度緩慢，且決策行為往往表現得過度保守與原地繞路。

第三章：OM-SARL 注意力強化導航之核心架構與 MDP 模型

為了全面克服前述幾何演算法的互惠迷思，以及早期 DRL 模型的資訊遺失與無序性限制，本研究聚焦於 OM-SARL 注意力強化社交導航架構。該架構的核心精髓在於引入「自注意力機制 (Self-Attention Mechanism)」，將人群避障問題升級為無損的群體全域博弈。

3.1 馬可夫決策過程 (MDP) 數學建模

OM-SARL 將機器人在多行人擁擠環境中的社交導航行為，嚴謹地建模為一個連續時間的馬可夫決策過程 (Markov Decision Process, MDP)。其核心三要素定義如下：

3.1.1 狀態空間 (State Space, $\mathcal{S}$)

系統的總狀態由機器人自身的巨觀狀態與全體行人的狀態共同構成：

- **機器人自身狀態 ($\mathcal{S}_r$)**：包含機器人當前在世界座標系下的位置 (p_x, p_y) 、當前線速度與角速度 (v_x, v_y) 、物理半徑 r_r 、車頭朝向角度 θ 、偏好速度 v_{pref} ，以及目標終點座標 (g_x, g_y) ，共計 9 維。
- **行人狀態 ($\mathcal{S}_h$)**：對於環境中的第 i 位行人，其狀態包含其絕對位置 $(p_{x,i}, p_{y,i})$ 、當前移動速度 $(v_{x,i}, v_{y,i})$ 、以及該行人的物理半徑 $r_{h,i}$ ，共計 5 維。
- **局部地圖張量 (Occupancy Grid Map, $\mathcal{OM}$)**：為了增強對密集障礙物的局部感知，架構中特別集成了 $\mathcal{OM}$ 結構。其形狀大小定義為：

$$\text{Shape}_{\mathcal{OM}} = N_{\text{行人數}} \times 4_{\text{橫}} \times 4_{\text{縱}} \times 5_{\text{維度}}$$

用以精準捕捉每個人周圍的小型局部地圖網格數據。

3.1.2 動作空間 (Action Space, $\mathcal{A}$)

為了解決連續控制下流暢轉向與強化學習動作探索 (Exploration) 的平衡，OM-SARL 將動作空間離散化為 **80 種離散動作組合**。這 80 種組合是由 **5 種不同的前進速度**（等距劃分至偏好速度 v_{pref} ）與 **16 種均勻分佈的轉向角度**（ 360° 全向均分）進行笛卡爾積組合而成：

$$|\mathcal{A}| = 5 \times 16 = 80 \text{ 種離散動作}$$

3.1.3 獎勵函數 (Reward Function, $\mathcal{R}$)

為了引導 AI 大腦同時學會「快速抵達終點」、「絕對不撞人」以及「禮貌遠離他人空間」這三種衝突的行為，獎勵函數設計為一組分段式的精準數學公式：

$$\mathcal{R}(s, a) = \begin{cases} 1 & \text{若機器人抵達終點目標} \\ -0.25 & \text{若與任何行人發生物理碰撞} \\ -0.1 + \frac{d_{\min}}{2} & \text{若侵入人類社交舒適圈 (即距離 } d_{\min} < 0.2 \text{ m)} \\ \text{Potential-based Reward} & \text{其餘正常行進時間 (引導向終點推進)} \end{cases}$$

此處的侵入社交圈處罰項（ -0.1 ）能強迫機器人在訓練中自發學會保持社交

距離。

第四章：網路管道模組深度拆解：從個體萃取到全域注意力融合

OM-SARL 的神經網路管道 (Pipeline) 可以優雅地拆解為三大模組：**互動模組 (Interaction Module)**、**動態注意力權重分配模組 (Pooling Module)** 以及 **規劃模組 (Planning Module)**。本章深入剖析其內部特徵流動維度。

4.1 互動模組 (Interaction Module)：特徵空間變形

互動模組的核心功能是**萃取每位行人與周圍環境及機器人之間的局部空間相對幾何關係**。其內部特徵流動經歷了一次大膽的幾何變換與降維增維工程（如圖 9 所示）：

4.1.1 輸入層的幾何特徵工程（60 維）

原生的機器人 9 維與行人 5 維世界座標，首先經過一個局部座標系轉換函數（以機器人為原點，車頭朝向為 Y 軸正向）。轉換後，輸入向量被重新構造為以下三個特徵的拼接，**總計 60 維**：

1. **機器人局部狀態 (Robot State, 5 維)**：剔除絕對座標後的 $\{\text{目標距離}, \text{偏好速度}, \text{當前速度}_x, \text{當前速度}_y, \text{物理半徑}\}$ 。
2. **行人局部狀態 (Human State, 7 維)**：特別幫神經網路算好的顯式特徵，包含 $\{\text{行人到機器人距離 } d_g, \text{相對座標 } x, \text{相對座標 } y, \text{局部速度}_x, \text{局部速度}_y, \text{行人半徑}, \text{兩者半徑總和}\}$ 。
3. **局部地圖特徵 (Local Map M_i , 48 維)**：代表該行人周圍的局域佔據網格特徵。

$$\text{Total Input Dim} = 5 + 7 + 48 = 60 \text{ 維} \quad [\text{cite: 109}]$$

4.1.2 輸出層的高維提取


這 60 維的融合向量被送入互動模組的內嵌全連接層 MLP1 中進行特徵非線性放大，最終吐出兩個核心特徵：

- **個體全特徵向量 e_i (Individual Feature)**：維度為 **100 維**，完整保留了該行人的時空幾何全貌。
- **隱藏特徵向量 h_i (Hidden Feature)**：維度為 **50 維**，作為後續注意

力權重乘算的高維骨架。

4.2 動態注意力權重分配模組 (Pooling Module)：Softmax 全域融合

在拿到每個人獨立算出的 100 維特徵 e_i 後，大腦需要將它們融合成一個大局觀特徵。這一步正是 OM-SARL 戰勝 CADRL 與 LSTM-RL 的終極突破點。



4.2.1 第一步：計算全域平均社交特徵 e_m

為了消除輸入人數的限制，並達成空間上的無序對稱性，演算法利用一個平均值池化層 (Mean Pooling)，將廣場上所有行人計算出的 100 維特徵向量 e_i, e_j 沿著人數軸進行完全對稱的加總平均：

$$e_m = \frac{1}{N} \sum_{i=1}^N e_i \quad \text{(\text{維度固定為 100 維})}$$

[cite: 120]

這個 e_m 在物理意義上代表了「當前整個人群整體的宏觀擁擠程度與平均流向大局觀」。

4.2.2 第二步：拼接大局觀，求解潛意識衝突得分 α_i

接著，程式碼將「個體特徵 e_i 」與剛算出的「全域大局觀 e_m 」強行橫向拼接，拼成一個 200 維的綜合向量，送進注意力網路 MLP2 中：

$$\text{Raw Score } \alpha_i = \text{MLP2}(e_i, e_m) \quad \text{(\text{輸出為 1 維純量})}$$

[cite: 114, 116]

這個 α_i 方塊代表機器人潛意識裡覺得「行人 i 在全體人群大局觀下，對我的潛在物理威脅度得分」。

4.2.3 第三步：Softmax 抉擇防線，輸出標準權重

由於原始得分 α_i, α_j 的數值範圍極不固定，大腦利用一個 **Softmax 歸一化層**，將所有人得到的原始分數轉化為加總等於 100% 的動態權重機率分佈：

$$P(\alpha_i) = \frac{e^{\alpha_i}}{\sum_{j=1}^N e^{\alpha_j}} \quad \text{[cite: 123]}$$

這個最終走過 Softmax 框框的完成品，就是你在影片左上角看到的動態注意力百分比（例如 human 3: 0.24）！

4.2.4 第四步：全域加權求和，煉製無損社交特徵 c

最後，大腦將 Softmax 產出的各行人注意力百分比，回頭去乘上他們在互動模組中被提煉出的 50 維隱藏狀態 h_i, h_j ，並進行加權求和（ Σ ）：

$$c = \sum_{i=1}^N P(\alpha_i) \cdot h_i \quad \text{(維度固定為 50 維)} \quad \text{[cite: 132]}$$

這個 c （全域社交特徵）堪稱數學上的傑作，不論環境中人數是 5 人還是 50 人，經過這個機制的淬煉，最終都會被無損、等價地濃縮為一條固定 50 維的精華向量，徹底克服了固定輸入與無序性的魔咒。

4.3 規劃模組 (Planning Module) 與雙階段訓練機制

4.3.1 終極導航價值預測網路 f_v

當全域社交特徵 c 被成功提煉出來後，它會與機器人自身轉向後的 5 維局部狀態 s （self_state）進行最後的拼接，建立起 **joint_state**（聯合狀態向量，共 55 維）。這個聯合狀態會被送入名為 f_v 的規劃神經網路（由 150 -> 100 -> 100 -> 1 的三層 Hidden Layer 構成）：

$$V(s) = f_v(s, c; W_v) \quad \text{(輸出 1 維純量分數)} \quad \text{[cite: 135, 139]}$$

這個 $V(s)$ 分數直接代表了「機器人在當前人群包圍的局勢下，若採取某個動作前進，在未來能拿到的累積獎勵預期期望值 (Value)」。機器人只需遍歷其 80 種離散動作，挑選出能讓 $V(s)$ 得分最高的那個動作去執行，即可實現神經網路導航。

4.3.2 雙階段訓練機制 (Two-Stage Training)

為了讓這套複雜的全域注意力大腦從零開始順利收斂，OM-SARL 採用了精妙的雙階段訓練戰術：

[階段一: 模仿學習 (3000 次)] —> [階段二: 強化學習 (10000 次)] —> 誕生終極社交大腦

(死記硬背 ORCA 標準答案)
禮儀)

(利用 Reward 探索與微調社交

1. 階段一：模仿學習 (Imitation Learning)

- **策略：**在訓練的前 3000 次 Episodes 中，強迫 AI 大腦進行「死記硬背」。演算法直接調用 ORCA 幾何演算法跑出成千上萬局的行進軌跡，將其作為「專家標準答案 (Ground Truth)」餵給神經網路。AI 透過監督式學習的反向傳播，快速讓網路的初期權重對齊幾何避障的基本盤。這一步極大地縮短了後期盲目探索的時間。

2. 階段二：強化學習 (Reinforcement Learning)

- **策略：**在打好基本功後，接下來的 10000 次 Episodes 切換為真正的強化學習模式。此時，斷開 ORCA 的拐杖，讓機器人獨自進入充滿動態行人的模擬圓環環境中進行自主試錯。AI 透過前述設計的 Reward Function 進行策略梯度的微調，在實踐中不斷碰壁與修正，進而學會 ORCA 所無法企及的「提早解讀人類意圖、不干擾對話、優雅穿梭」等符合人類社交禮儀的終極避障軌跡。

第五章：系統實作、環境實測與多維度指標對比分析

5.1 實驗環境設定與硬體配置

本研究之模擬實驗與訓練，均在一台配備工業級主流規格的運算工作站上執行，以確保數據的客觀性與可重複性，其具體硬體與軟體資源配置如下：

- **中央處理器 (CPU)：**Intel Core i7-10700
- **圖形處理器 (GPU)：**NVIDIA GeForce RTX 3070TI
- **軟體環境與人工智慧框架：**基於 Linux 系統環境，核心採用 **PyTorch** 深度學習生態框架進行張量矩陣運算與網路重構。
- **資料集與局數劃分：**在模型評估與效能驗證上，整體數據集共劃分為：訓練集 (Train，大於 2000 局)、驗證集 (Val，1000 局) 以及最終的測試集 (Test，1000 局)。

- **模擬場景設定**：測試環境設定在一個規律的二維模擬圓環內，隨機產生 **5 名物理半徑與行走速度完全相同的行人**。為了極端測試演算法在非合作環境下的表現，設定**機器人對行人是完全「隱形（Invisible）」**的。這意味著行人會盲目遵循自己的軌跡往前走，完全不會主動禮讓機器人，機器人必須百分之百承擔起全域避障與維護社交規範的責任。雙方皆具備 **360 度無死角全向視野**，其中 **LSTM-RL** 受到其佔據地圖特徵限制，局部視野上限約為 **2 公尺**。

5.2 累積獎勵曲線與訓練時間成本分析

通盤考察四種演算法（ORCA、CADRL、LSTM-RL、OM-SARL）在 10000 次 Episodes 強化學習訓練過程中的收斂表現，其「累積折現獎勵曲線（Cumulative Discounted Reward）」展現出截然不同的工程權衡（Trade-off）特徵（如圖 13 所示）：

[訓練時間與收斂特徵對比]

1. CADRL —————> 耗時: 14 小時 14 分 —> 訓練最快，但極易震盪與資訊遺失 [cite: 184, 185]

2. LSTM-RL —————> 耗時: 21 小時 38 分 —> 學習曲線平穩，但收斂速度極其緩慢 [cite: 187, 188]

3. OM-SARL —————> 耗時: 26 小時 25 分 —> 獲得最高穩定獎勵值，伴隨巨大矩陣代價 [cite: 191, 192]

- **CADRL**：總訓練耗時僅需 **14 小時 14 分鐘**，是所有學習模型中訓練速度最快的。然而，其獎勵曲線在後段出現了劇烈的上下震盪，這證實了其由於固定輸入向量導致的「資訊遺失」，使得模型在面對部分高密度場景時會發生策略崩潰。
- **LSTM-RL**：總訓練耗時為 **21 小時 38 分鐘**。得益於循環網路的序列輸入，其學習曲線表現得相對平穩，但上升斜率極低，收斂速度極其緩慢，這直接呼應了第二章所提及的——LSTM 無法處理空間「無序性」導致的 Hidden State 數值混亂瓶頸。
- **OM-SARL（全域注意力）**：其總訓練耗時高達 **26 小時 25 分鐘**，相較

於 CADRL 增加了將近 **85%** 的時間成本。這項巨大的工程代價源自於自注意力機制中高昂的動態矩陣博弈運算。然而，付出代價的收穫是，其獎勵曲線在 4000 局後便以無可爭辯的昂揚姿態奪下了全場最高的穩定獎勵值，且後續波形極其絲滑，展現出完美的數學收斂特性。

5.3 500 局標準測試最終評估定量分析

為了發揮嚴謹的學術精神，本研究將四種模型部署到完全不參與訓練的 500 局標準獨立測試場景中進行定量跑分，核心幾何指標對比匯整如下表：

表 5.1：不同導航避障演算法之 500 局標準測試性能對比表

評估模型	導航成功率 (%)	物理碰撞率 (%)	平均導航時間 (s)	社交危險平均距離 (m)
ORCA (傳統幾何派)	43.0%	57.0%	10.86s	0.08m
CADRL (早期學習派)	90.0%	8.0%	11.27s	0.13m
LSTM-RL (時間序列派)	98.0%	1.0%	11.95s	0.11m
OM-SARL (全域注意力)	100.0%	0.0%	10.57s	0.16m

深度指標解讀：

1. 成功率與碰撞率的碾壓 傳統幾何派的 **ORCA** 慘遭滑鐵盧，成功率僅有 **43.0%**，碰撞率高達 **57.0%**。這給工業界帶來了強烈警訊：在行人完全不禮讓機器人的「非合作極端密集場域」中，ORCA 基於 50/50 的互惠假設會完全崩塌。反觀 **OM-SARL**，交出了 **100.0%** 完美成功率與 **0.0%** 碰撞率的無懈可擊答卷，充分證明了全域注意力機制的強大安全防護能力。

2. **平均導航時間 (Navigation Time)** 許多人誤以為安全性高意味著行進速度必須變慢，但數據給出了反直覺的結論：**OM-SARL 的平均導航時間僅需 10.57 秒，是全場跑得最快的演算法！** 相比之下，LSTM-RL 雖然成功率高達 98.0%，但其耗時高達 11.95 秒。這說明 LSTM-RL 由於缺乏精準預判，在真實避障時往往表現得極度保守、頻繁原地停頓與繞遠路；而 OM-SARL 則像一個身手矯健的橄欖球員，能一目了然地看穿人群的動態縫隙，並以最短的絲滑路徑一衝到終點。
3. **社交禮儀定量化：社交危險平均距離** 這項指標代表機器人在與行人擦身而過時，彼此物理邊緣的最短距離。ORCA 只有 0.08m，幾乎是貼著行人的衣角驚險擦過，屬於嚴重侵犯人類心理圈的失禮行為；而 **OM-SARL 成功將該距離維持在 0.16m**，這完美符合了社會學中所定義的「社交禮貌舒適邊界」，達成了真正的人類社交禮儀。

5.4 空間風險感知與避障軌跡診斷

為了進一步窺探 AI 大腦在行進過程中的潛意識思維，本研究抽取了「第 5 秒極端擁擠場景」下，各演算法對周圍空間風險感知的極坐標熱圖（Polar Risk Map，如圖 15 所示）以及實際避障軌跡全紀錄（Trajectory Diagnostic，如圖 16 所示）進行深度對照：

5.4.1 ORCA：死鎖與迎面碰撞

- **幾何現象診斷：**在第 5 秒交會時，由於多個行人的幾何半平面約束在數學上發生了嚴重的重疊重合，導致速度空間無解。ORCA 瞬間觸發了「機器人凍結效應」，輸出速度歸零死鎖。然而此時，迎面走來的行人（對機器人隱形）並不會停步，最終直接將動彈不得的機器人迎面撞翻。

5.4.2 CADRL：資訊遺失導致突兀轉向

- **幾何現象診斷：**觀察其風險感知熱圖，其顏色分佈顯得極其零散、混亂且發散，完全無法聚焦鎖定特定的核心威脅。反映在軌跡圖上，機器人在前 4 秒走得歪歪扭扭（非最佳路徑）；當第 5 秒人群大量逼近時，因為網路維度限制將外圍行人的特徵粗暴丟棄，發生了嚴重的「資訊遺失」，導致機器人直到最後一刻才猛然驚醒，甩出一個極其突兀且令人驚嚇的急轉彎。

5.4.3 LSTM-RL：極度保守與原地繞行

- **幾何現象診斷：**其極坐標熱圖呈現出一種均勻、圓潤但過度發散的亮黃色。這意味著其空間感知「過於保守且均勻」。因為它無法對不同威脅度的行人進行精確的權重區隔，導致大腦草木皆兵，誤判定周圍 360 度到處都是高風險區，缺乏明確的突圍方向。在軌跡圖中，它表現為在走廊中央出現明顯的長時間停頓，並拉出了一條極其誇張、大範圍繞遠路的半圓形保守軌跡，嚴重犧牲了導航效率。

5.4.4 OM-SARL：提前預判與絲滑突圍

- **幾何現象診斷：**其極坐標感知熱圖展現出極高的特徵美感——熱圖在 45° 到 90° 的扇形區域呈現出精準鎖定的高亮黃色危險警報，而其餘不具威脅的角度則呈現深紫色。這證明全域注意力機制成功賦予了大腦精準鎖定特定高風險區塊的動態解讀能力，並藉此計算出了最佳的突圍向量（Breakthrough Vector）。在軌跡上，OM-SARL 表現得優雅而流暢，它在距離人群還有 3 公尺時便透過動態權重「提早預判」到了未來的衝突，進而提前切入一條弧度極其優美、不干擾人類對話、近乎流體力學般的絲滑避障軌跡，展現了真正的智慧社交禮儀。

第六章：研究結論與未來技術藍圖探討

6.1 研究總結與三大核心洞見

本研究全面拆解並定量驗證了基於全域注意力機制的 OM-SARL 移動機器人社交導航演算法，從幾何控制的失效到深度神經網路的重構，得出了以下三項極具學術與工程價值的核心洞見：

1. 「互惠假設」在現實非合作環境中的破滅 傳統 ORCA 幾何避障演算法在 500 局標準測試中高達 **57.0%** 的碰撞率，給機器人產業敲響了警鐘。在真實世界中，將避障責任寄望於人類會做出 50/50 的對等互惠避讓是一項極其危險的盲目假設。在人機共存場域中，由機器人單方面承擔起全域避障與維護社交安全的責任，才是確保系統本質安全的唯一解。
2. 注意力機制是破解「機器人凍結」的終極利器 藉由「個體特徵 e_i 」與「全域大局觀 e_m 」的 Softmax 動態博弈，OM-SARL 成功打破了密集人群中的死鎖狀態，達成了 **100%** 的導航成功率與 **0%** 的碰撞

率。這項突破雄辯地證明了，自注意力機制能柔和且無損地保留環境中的全域特徵，引導機器人在擁擠狹縫中尋求最優解。

3. **安全性與時間成本的「工程權衡 (Trade-off)」** 在工程實踐中，OM-SARL 導致網路複雜度與訓練時間顯著增加了 85%（高達 26.4 小時）。然而，這種離線訓練階段付出的代價，成功換取了在線部署時「完美的物理安全性（0% 碰撞）」以及「最快、最不遲疑的即時導航效率（10.57s）」。這是一項非常划算且完全符合工業界預期的最優工程權衡。

6.2 未來技術藍圖與前沿展望

為了進一步推動移動機器人社交導航技術走向成熟，本研究依據當前具備巨大突破潛力的前沿人工智慧技術，規劃出三大未來技術藍圖：

- **藍圖一：逆向強化學習 (Inverse Reinforcement Learning, IRL) 的引入**
 - **核心痛點：**目前的獎勵函數仍高度依賴工程師依據幾何經驗進行手工調校（如抵達 $\$=1\$$ ，侵入 $\$=-0.1\$$ ），這種手動權重設定在面對更複雜的人類社交行為（如排隊、讓座、禮讓博弈）時會顯得極其捉襟見肘。
 - **解決路徑：**未來可引入逆向強化學習（IRL）架構，直接收集大量真實人類在公共走廊上擦身而過的真實行走軌跡數據，讓機器人透過 IRL 自主逆向萃取出隱含在人類大腦中的 **Reward Function**，這將賦予社交導航機器人更高維度的環境泛化與自適應能力。
- **藍圖二：結合「擴散模型 (Diffusion Models)」的連續軌跡生成**
 - **核心痛點：**OM-SARL 當前將動作空間限制在 80 種離散的速度與角度組合中，雖然降低了強化學習的探索難度，但在某些極端狹窄場域，離散控制仍可能導致微小的機械式鋸齒震盪，無法達到真正的完全連續絲滑。
 - **解決路徑：**未來研究可嘗試引入當前在前沿 AI 領域大放異彩的「擴散模型 (Diffusion Models)」，將擴散模型的去噪生成機制與現有的 Actor 網路相結合，直接取代生硬的離散動作空間，輸出完全連續且更符合流體力學的超高規格絲滑避障動作。

- **藍圖三：結構優化與注意矩陣輕量化 (Attention Optimization)**
 - **核心痛點：**全域注意力機制高昂的矩陣博弈運算，是導致訓練時間大幅拉長到 26.4 小時的罪魁禍首。
 - **解決路徑：**為了將該演算法推向更低運算算力的嵌入式邊緣晶片（如 Raspberry Pi、Jetson Nano），未來的關鍵工程任務在於精簡與輕量化注意力機制的矩陣運算。透過引入稀疏注意力（Sparse Attention）或 FlashAttention 等結構優化技術，大幅降低運算代價，從而在維持完美安全性的前提下，將高昂的訓練與推理時間成本徹底打下來。

參考文獻 (References)

1. D. Helbing and P. Molnar, "Social force model for pedestrian dynamics," *Physical Review E*, 1995.
2. J. van den Berg et al., "Reciprocal velocity obstacles for real-time multi-agent navigation," *ICRA*, 2008.
3. J. van den Berg et al., "Reciprocal n-body collision avoidance," *Robotics Research*, 2011. (ORCA)
4. R. Alami et al., "Safe and acceptable navigation in human environments," *IEEE ICRA*, 2006.
5. Y. F. Chen et al., "Decentralized non-cooperative multi-agent collision avoidance with deep reinforcement learning," *ICRA*, 2017. (CADRL)
6. M. Everett et al., "Motion planning among dynamic, decision-making agents with deep reinforcement learning," *IROS*, 2018. (LSTM-RL)
7. P. Long et al., "Towards optimally decentralized multi-robot collision avoidance via deep reinforcement learning," *ICRA*, 2018.
8. C. Chen et al., "Crowd-robot interaction: Crowd-aware robot navigation with attention-based deep reinforcement learning," *ICCV*, 2019. (SARL)
9. S. Liu et al., "Decentralized structural-RNN for robot navigation in crowds," *ICRA*, 2020.

10. C. Chen et al., "Relational graph learning for crowd navigation," *IROS*, 2020.
11. O. Wang et al., "Intention-aware robot navigation in crowds with multi-agent reinforcement learning," *IEEE RA-L*, 2021.
12. S. Zhou et al., "Socially attentive navigation using deep reinforcement learning and transformer networks," *IEEE T-RO*, 2022.
13. S. Yao et al., "Contrastive learning for socially aware robot navigation," *ICRA*, 2023.
14. A. Khan et al., "Memory-augmented graph neural networks for multi-robot navigation," *IEEE RA-L*, 2021.
15. B. Yuan and K. Driggs-Campbell, "Risk-aware crowd navigation via distributional learning and transformer attention," *IEEE T-ASE*, 2024.
16. J. Li et al., "Conditional generative trajectory planning for socially aware robot navigation," *IROS*, 2022.
17. L. Sun et al., "Deep reinforcement learning with predictive attention for crowd navigation," *IROS*, 2023.
18. T. Zhang et al., "Multi-agent reinforcement learning for decentralized drone swarm navigation in dense crowds," *IEEE T-CYB*, 2024.
19. Y. Xu and S. Martinez, "Safe multi-agent reinforcement learning for social navigation via control barrier functions," *IEEE TCST*, 2025.
20. D. Szafir et al., "Designing social signals for unmanned aerial vehicles in human-in-the-loop systems," *ACM THRI*, 2017.
21. A. Rodriguez-Serrano and S. Martinez, "Decentralized collision avoidance for drone swarms using deep reinforcement learning and PX4 simulation," *JINT*, 2022.